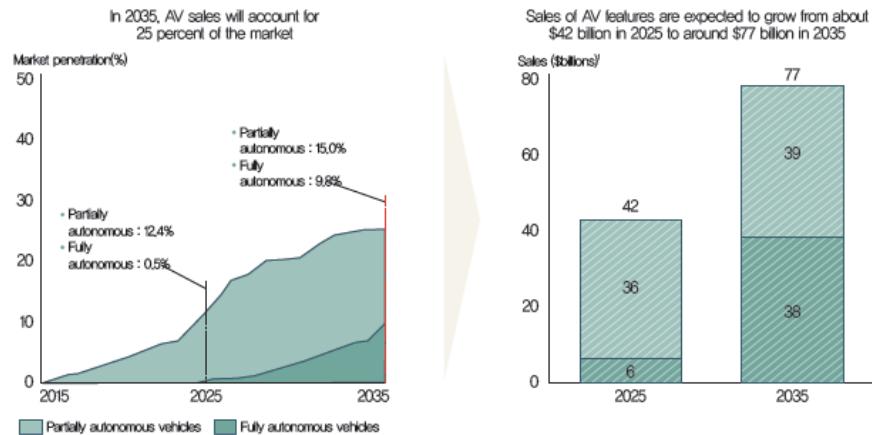


목차

- I. 연구 배경
- II. 관련 연구
- III. 문제 정의
- IV. 제안 방법
- V. 실험
- VI. 결론 및 개선 방향

I. 연구 배경 – 자율주행차 시장 전망

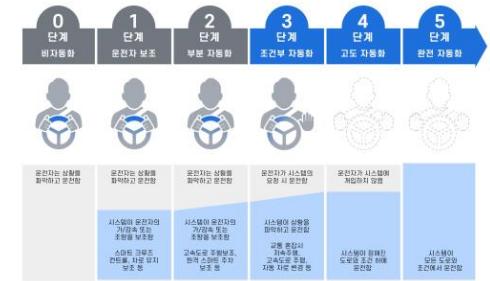
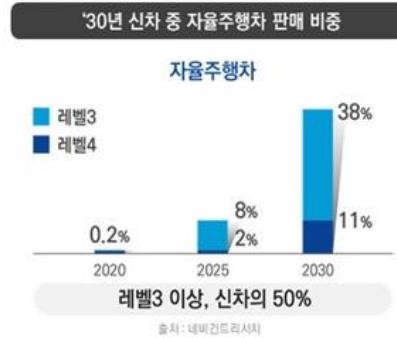
전세계 자율주행차 성장을 전망



※ 자료 : 보스턴컨설팅그룹(BCG)

- 전세계 자율주행차 점유율 2025년 12.9% → 2035년 25%
- 자율주행차 시장 규모 2025년 420억 달러 → 2035년 770억 달러

자율주행차 시장규모 및 판매 비중 전망



- 신차 중 자율주행차 판매 비중은 전체 신차 중 약 50% 가량 차지

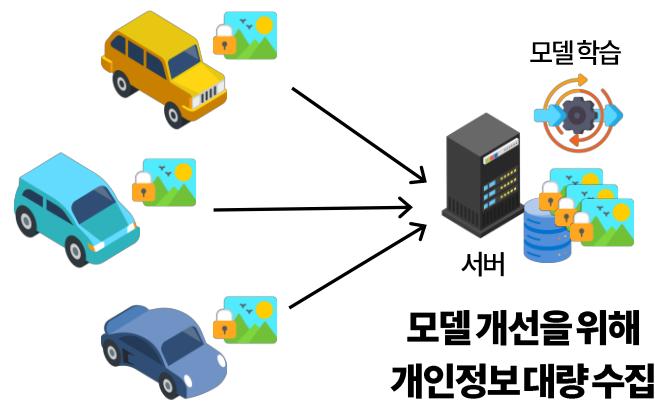
I. 연구 배경 - 자율주행차 성능과 개인정보 보호

자율주행차의 안전과 성능은 각 기능을 담당하는 머신러닝 모델의 성능이며, 자율주행차의 데이터는 개인정보이기에 중앙 서버에 일괄 보관하는 것은 개인정보 유출이나 침해를 일으킬 수 있음

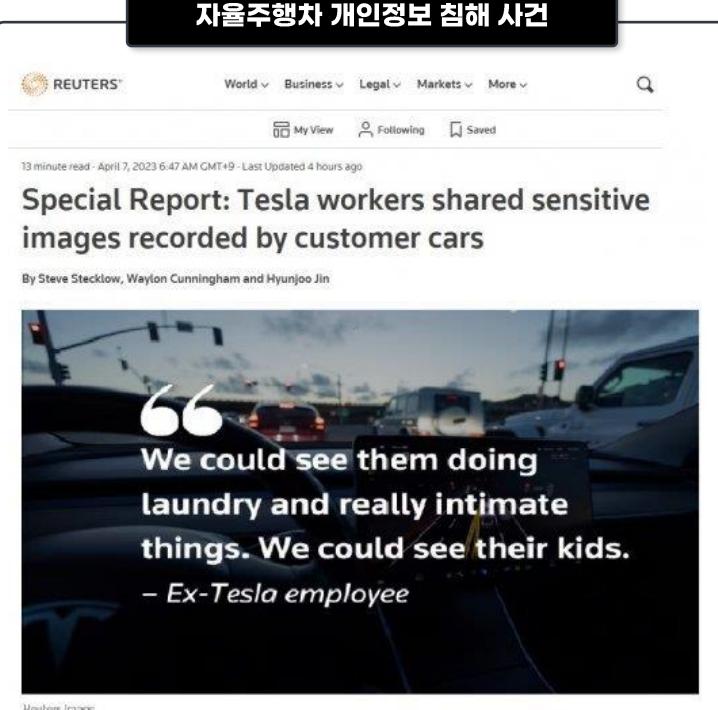
차량 주행 데이터에 포함된 개인정보



- 음성 데이터
- 위치 정보 데이터
- 보행자 얼굴 데이터



자율주행차 개인정보 침해 사건



REUTERS

World Business Legal Markets More

My View Following Saved

13 minute read - April 7, 2023 6:47 AM GMT+9 - Last Updated 4 hours ago

Special Report: Tesla workers shared sensitive images recorded by customer cars

By Steve Stecklow, Waylon Cunningham and Hyunjoo Jin

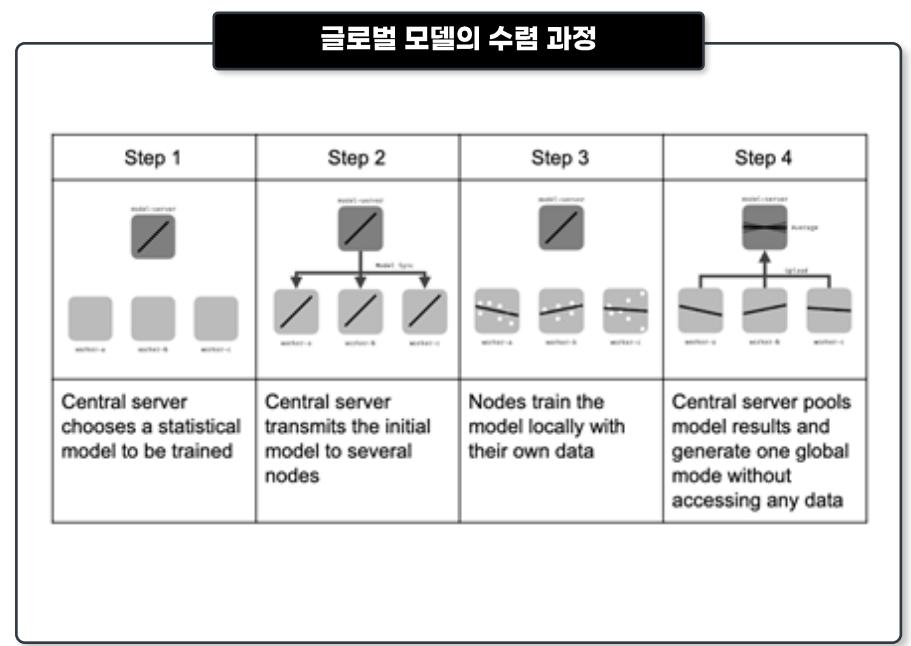
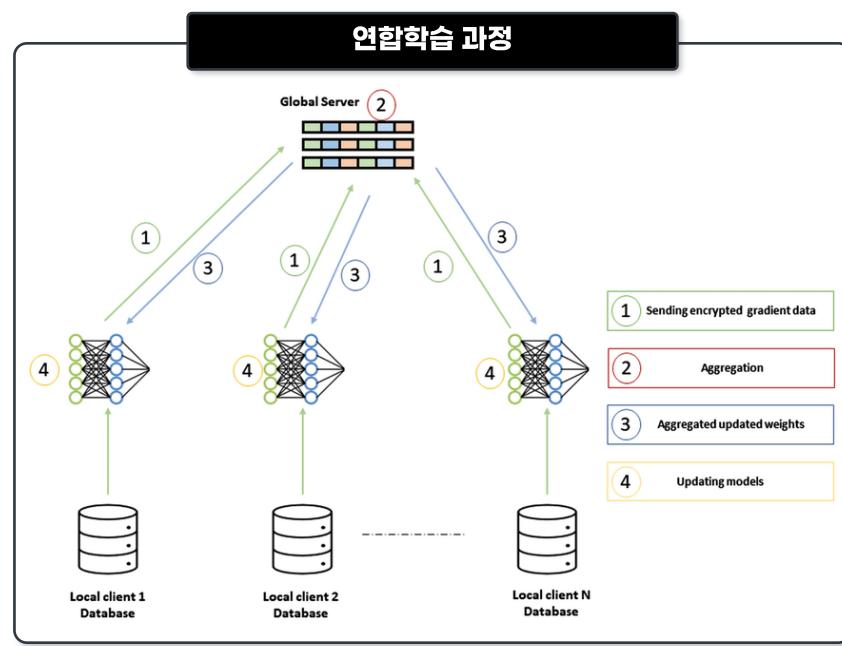
We could see them doing laundry and really intimate things. We could see their kids.
- Ex-Tesla employee

- 녹화된 데이터는 익명 처리된다고 하나, 데이터가 서버에 보관되고 있어 데이터 유출, 침해는 100% 예방할 수 없음.
- 데이터를 전송하지 않고 모델을 학습할 수 있는 방법 필요



I. 연구배경 - 연합 학습

연합학습은 데이터를 서버로 전송하지 않고, 머신러닝 학습을 할 수 있는 연합 학습 방법으로 개인정보를 보호할 수 있음



- 클라이언트는 자신의 데이터로 로컬 모델을 학습하고, 서버로 전송하여 글로벌 모델을 생성
- 서버가 글로벌 모델을 클라이언트에게 배포하여 반복적으로 모델을 수렴

- 클라이언트의 모델은 서로 다를 수 있음.
- 서버는 다양한 로컬 모델을 반복적으로 집계하여 모든 클라이언트의 데이터를 학습한 글로벌 모델을 생성
- 이 과정에서 어떤 클라이언트를 참여시킬지에 대한 기준이 필요

I. 연구 배경 - 리튬 이온 배터리 수명

자율주행차는 리튬 이온 배터리를 주동력원으로 사용

자율주행차가 연합학습의 클라이언트로 참여한다면 학습 과정에서 배터리 전력을 소모

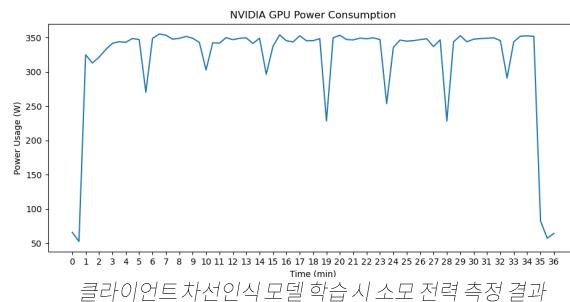
리튬 이온 배터리 수명 변화

Depth of discharge	Discharge cycles	Table 2: Cycle life as a function of depth of discharge
100% DoD	300 – 500	A partial discharge reduces stress and prolongs battery life. Elevated temperature and high currents also affect cycle life.
50% DoD	1,200 – 1,500	
25% DoD	2,000 – 2,500	
10% DoD	3,750 – 4,700	

* Battery Power Management for Portable Devices, Yevgen Barsukov, Jinrong Qian, BOOK.

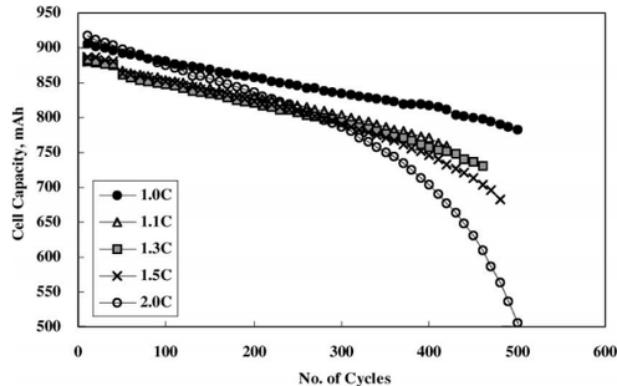
- 배터리 최대 용량이 70%로 줄어드는 방전 깊이(Depth of discharge) 별 충전 횟수
 - 매번 배터리를 100% 사용 시 300~500번 충전하면 배터리 용량이 70%로 줄음
 - 매번 배터리를 10%만 사용 시 3,750~4,700번 충전하면 배터리 용량이 70%로 줄음

머신러닝 학습에 필요한 전력



- GPU: Nvidia A6000
- 모델 학습 시 GPU 소모 전력 평균 약 0.3kW

충전-방전 속도에 따른 리튬 이온 배터리 수명 변화



* Factors that affect cycle-life and possible degradation mechanisms of a Li-ion cell based on LiCoO₂, Samsung SDI

- C-rate(Current Rate) 의미: 배터리를 충전 또는 방전시키는 속도를 나타내는 값
- C-rate = $\frac{\text{충전방전 전류(A)}}{\text{배터리용량(Ah)}} \times \frac{\text{충전방전전력(W)}}{\text{배터리용량(Wh)}}$
- 충전, 방전시 C-rate가 높으면 배터리의 최대 용량이 줄어듬.

- 모델 학습 시 클라이언트는 전력을 소모함
- 배터리 잔량이 낮을 수록, 충전 속도가 빠를 수록 배터리 수명을 줄임
- 단, 트레이드 오프 관계이기에 어느 것을 더 중요시 할지 결정 필요

배터리의 수명 최적화를 위해 배터리 잔량이 높고,
충전 속도가 느린 클라이언트에게 학습 참여 우선권

I. 연구 배경 - 연합학습 데이터 처리

연합학습은 서버와 클라이언트가 모델을 송수신하는 통신을 효과적으로 확인할 수 있는 시각화 도구 필요

Command Line Interface 기반 연합학습

서버

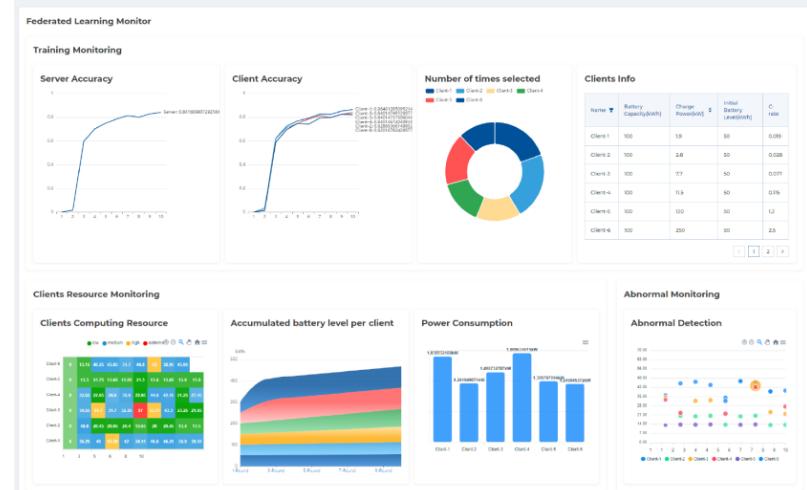
```
(torch) tj@carla:~/fl-carla/fl-module$ ./server.sh
1684765040.8934736
INFO flwr 2023-05-22 23:17:20,894 | app.py:148 | Starting Flower server, config: ServerConfig(num_rounds=10, round_timeout=None)
INFO flwr 2023-05-22 23:17:20,908 | app.py:168 | Flower gRPC server running (10 rounds), SSL is disabled
INFO flwr 2023-05-22 23:17:20,909 | server.py:86 | Initializing global parameters
INFO flwr 2023-05-22 23:17:20,909 | server.py:273 | Requesting initial parameters from one random client
INFO flwr 2023-05-22 23:17:50,900 | server.py:277 | Received initial parameters from one random client
INFO flwr 2023-05-22 23:17:50,900 | server.py:88 | Evaluating initial parameters
INFO flwr 2023-05-22 23:17:50,900 | server.py:101 | FL starting
액스! 0.077
DEBUG flwr 2023-05-22 23:17:50,998 | server.py:218 | fit_round 1: strategy sampled 3 clients (out of 3)
DEBUG flwr 2023-05-22 23:18:27,207 | server.py:232 | fit_round 1 received 3 results and 0 failures
WARNING flwr 2023-05-22 23:18:27,375 | fl_server.py:140 | No fit_metrics_aggregation_fn provided
액스! 0.077
DEBUG flwr 2023-05-22 23:18:27,377 | server.py:168 | evaluate_round 1: strategy sampled 3 clients (out of 3)
DEBUG flwr 2023-05-22 23:18:29,679 | server.py:182 | evaluate_round 1 received 3 results and 0 failures
WARNING flwr 2023-05-22 23:18:29,679 | fedavg.py:274 | No evaluate_metrics_aggregation_fn provided
Round 1 accuracy aggregated from client results: 0.00019378431898076087
액스! 0.077
DEBUG flwr 2023-05-22 23:18:29,683 | server.py:218 | fit_round 2: strategy sampled 3 clients (out of 3)
[]
```

클라이언트

```
(torch) tj@carla:~/fl-carla/fl-module$ ./spanner.sh
(torch) tj@carla:~/fl-carla/fl-module$ cuda
cuda
cuda
INFO flwr 2023-05-22 23:17:34,493 | grpc.py:50 | Opened insecure gRPC connection (no certificates were passed)
DEBUG flwr 2023-05-22 23:17:34,495 | connection.py:39 | ChannelConnectivity.IDLE
DEBUG flwr 2023-05-22 23:17:34,495 | connection.py:39 | ChannelConnectivity.CONNECTING
DEBUG flwr 2023-05-22 23:17:34,498 | connection.py:39 | ChannelConnectivity.READY
INFO flwr 2023-05-22 23:17:34,510 | grpc.py:50 | Opened insecure gRPC connection (no certificates were passed)
INFO flwr 2023-05-22 23:17:34,511 | grpc.py:50 | Opened insecure gRPC connection (no certificates were passed)
DEBUG flwr 2023-05-22 23:17:34,512 | connection.py:39 | ChannelConnectivity.IDLE
DEBUG flwr 2023-05-22 23:17:34,513 | connection.py:39 | ChannelConnectivity.CONNECTING
DEBUG flwr 2023-05-22 23:17:34,521 | connection.py:39 | ChannelConnectivity.READY
DEBUG flwr 2023-05-22 23:17:34,537 | connection.py:39 | ChannelConnectivity.IDLE
DEBUG flwr 2023-05-22 23:17:34,614 | connection.py:39 | ChannelConnectivity.READY
[]
```

- 클라이언트 수가 많아질 수록 CLI 환경에서는 연합학습의 상황을 판단하거나 평가하기 어려움

시각화 도구 기반 연합학습



- 연합학습 과정을 시각화 도구로 효과적으로 파악 가능

목차

- I. 연구 배경
- II. 관련 연구
- III. 문제 정의
- IV. 제안 방법
- V. 실험
- VI. 결론 및 개선 방향

II. 관련 연구 - 연합학습 대시보드 및 모니터링 도구

연합학습 대시보드 관련 연구, 오픈소스 프로젝트의 주요 기능 분석

주요 기능	HFLense	VADAF	FATE Board	FedML	Tensor Board	NVIDIA FLARE	제안 방법
연합학습 모델 훈련	O	O	O	O	O	O	O
연합학습 모델의 훈련, 검증, 평가 과정 모니터링	O	O	O	O	O	O	O
클라이언트 Resource 사용량 확인	X	X	O	O	O	O	O
이상 클라이언트 탐지	O	O	X	X	X	X	O
클라이언트 선택 방법 설정	X	X	X	X	X	X	O
클라이언트 배터리 상태 모니터링	X	X	X	X	X	X	O
자율 주행 차시뮬레이터 연동	X	X	X	X	X	X	O

- **HFLense:** Q. Li, X. Wei, H. Lin, Y. Liu, T. Chen and X. Ma, "Inspecting the Running Process of Horizontal Federated Learning via Visual Analytics," in *IEEE Transactions on Visualization and Computer Graphics*, vol. 28, no. 12, pp. 4085-4100, 1 Dec. 2022, doi: 10.1109/TVCG.2021.3074010 A. Sultana, M. Haque, L. Chen, F. Xu and X. Yuan, "Eiffel: Efficient and Fair Scheduling in Adaptive Federated Learning" in *IEEE Transactions on Parallel & Distributed Systems*, vol. 33, no. 12, pp. 4282-4294, 2022, doi: 10.1109/TPDS.2022.3187365
- **VADAF:** Linhao Meng, Yating Wei, Rusheng Pan, Shuyue Zhou, Jianwei Zhang and Wei Chen. 2021. VADAF: Visualization for Abnormal Client Detection and Analysis in Federated Learning. *ACM Trans. Interact. Intell. Syst.* 11, 3–4, Article 26 (December 2021), 23 pages. <https://doi.org/10.1145/3426866>

II. 관련 연구 - 클라이언트 선택 알고리즘

Study	Publication	Resource	Energy Consumption	Battery Life	Description
제안방법	-	O	O	O	자율주행차의 배터리 수명을 고려
EAFL	FedEdge'22	O	O	X	휴대폰의 배터리 잔량을 고려
OCEAN	TWC'21	O	O	X	에너지가 제약된 환경에서 클라이언트 네트워크 대역폭 할당
Oort	OSDI'21	O	X	X	클라이언트의 데이터 분포 및 시스템의 이질성 고려
FedCS	ICC'19	O	X	X	특정 시간 내 최대한 많은 클라이언트 선택
Eiffel	TPDS'22	O	X	X	리소스 수요와 로컬 업데이트 빈도를 고려
FCFL	IMWUT'22	O	X	X	네트워크 자원이 제약된 환경에서 의 웨어러블 장치를 고려

- EAFL : Amna Arouj and Ahmed M. Abdelmoniem. 2022. Towards energy-aware federated learning on battery-powered clients. In Proceedings of the 1st ACM Workshop on Data Privacy and Federated Learning Technologies for Mobile Edge
- OCEAN: Jie Xu, Heqiang Wang "Client Selection and Bandwidth Allocation in Wireless Federated Learning Networks: A Long-Term Perspective", 2020, <http://arxiv.org/abs/2004.04314>, arXiv:2004.04314.
- Oort: Fan Lai, Xiangfeng Zhu, Harsha V. Madhyastha, Mosharaf Chowdhury Oort: Efficient Federated Learning via Guided Participant Selection. In 15th USENIX Symposium on Operating Systems Design and Implementation (OSDI'21) 2021 (pp. 19–35). USENIX Association.
- FedCS: Takayuki Nishio, Ryo Yonetani: "Client Selection for Federated Learning with Heterogeneous Resources in Mobile Edge", 2018, Proc IEEE ICC 2019, Shanghai, China, May 2019; Eiffel: A Sultana, M. Haque, L. Chen, F. Xu and X. Yuan, "Eiffel: Efficient and Fair Scheduling in Adaptive Federated Learning" in IEEE Transactions on Parallel & Distributed Systems, vol. 33, no. 12, pp. 4282-4294, 2022. doi: 10.1109/TPDS.2022.3187365
- FCFL : Pengyuan Zhou, Hengwei Xu, Lik Hang Lee, Pei Fang, and Pan Hui. 2022. Are You Left Out? An Efficient and Fair Federated Learning for Personalized Profiles on Wearable Devices of Inferior Networking Conditions. Proc. ACM Interact. Mob. Wearable Ubiquitous Technol. 6, 2, Article 91 (July 2022), 25 pages. <https://doi.org/10.1145/3534585>

목차

- I. 연구 배경
- II. 관련 연구
- III. 문제 정의
- IV. 제안 방법
- V. 실험
- VI. 결론 및 개선 방향

III. 문제 정의

Command Line Interface 기반 연합학습

```
[torch] [~/caristi-fti-caristi/fti-models] /server.sh
서버
INFO [2023-05-22 23:18:29,094] | loss.py:148 | Starting Fitter server, config: ServerConfig(max_rounds=10, round_timeout=None)
INFO [Fitter 2023-05-22 23:18:29,098] | loss.py:168 | Fitter: EC2 gRPC server running (10 rounds), SS is disabled
INFO [Fitter 2023-05-22 23:18:29,099] | server.py:273 | Requesting initial parameters from one random client
INFO [Fitter 2023-05-22 23:18:29,099] | server.py:277 | Received initial parameters from one random client
INFO [Fitter 2023-05-22 23:18:29,099] | server.py:281 | Received initial parameters
INFO [Fitter 2023-05-22 23:18:29,099] | server.py:181 | FL starting
INFO [Fitter 2023-05-22 23:18:29,099] | server.py:218 | fit round 1: strategy sampled 3 clients (out of 3)
INFO [Fitter 2023-05-22 23:18:29,099] | server.py:181 | FL starting
INFO [Fitter 2023-05-22 23:18:29,099] | server.py:168 | Fitter: EC2 gRPC server running (10 rounds), SS is disabled
WARNING [Fitter 2023-05-22 23:18:27,377] | server.py:168 | No metric aggregation_fn provided
    에스스: 0.007
INFO [Fitter 2023-05-22 23:18:27,377] | server.py:168 | evaluate round 1: strategy sampled 3 clients (out of 3)
DEBUG [Fitter 2023-05-22 23:18:29,679] | server.py:182 | evaluate round 1 received 3 results and 8 failures
INFO [Fitter 2023-05-22 23:18:29,679] | server.py:182 | evaluate round 1 aggregated results and metric aggregation_fn provided
    Round 1 accuracy aggregated from Client results: 0.00033705431000000007
    에스스: 0.007
INFO [Fitter 2023-05-22 23:18:29,683] | server.py:218 | fit round 2: strategy sampled 3 clients (out of 3)
    에스스: 0.007
[torch] [~/caristi-fti-caristi/fti-models] cuda
cuda
INFO [Fitter 2023-05-22 23:17:34,453] | grpc.py:59 | Opened insecure gRPC connection (no certificates were passed)
DEBUG [Fitter 2023-05-22 23:17:34,495] | connection.py:29 | ChannelConnectivity.IDLE
DEBUG [Fitter 2023-05-22 23:17:34,495] | connection.py:29 | ChannelConnectivity.CONNECTING
DEBUG [Fitter 2023-05-22 23:17:34,518] | connection.py:29 | ChannelConnectivity.RETRY
INFO [Fitter 2023-05-22 23:17:34,518] | grpc.py:59 | Opened insecure gRPC connection (no certificates were passed)
INFO [Fitter 2023-05-22 23:17:34,518] | grpc.py:59 | Opened insecure gRPC connection (no certificates were passed)
DEBUG [Fitter 2023-05-22 23:17:34,531] | connection.py:29 | ChannelConnectivity.CONNECTING
DEBUG [Fitter 2023-05-22 23:17:34,531] | connection.py:29 | ChannelConnectivity.CONNECTED
DEBUG [Fitter 2023-05-22 23:17:34,531] | connection.py:29 | ChannelConnectivity.READY
DEBUG [Fitter 2023-05-22 23:17:34,531] | connection.py:29 | ChannelConnectivity.IDLE
DEBUG [Fitter 2023-05-22 23:17:34,614] | connection.py:39 | ChannelConnectivity.IDLE
    
```

• 클라이언트 수가 많아질 수록 CLI 환경에서는 연합학습의 상황을 판단하거나 평가하기 어려움

시각화 도구 기반 연합학습

• 연합학습 과정을 시각화 도구로 효과적으로 파악 가능

문제 정의

1. 연합학습의 클라이언트 학습 데이터 분석과 처리
2. 자율주행 배터리 수명을 고려한 연합학습 성능 모니터링

리튬 이온 배터리 수명 변화

Depth of discharge	Discharge cycles
100% DoD	300 ~ 500
50% DoD	1,200 ~ 1,500
25% DoD	2,000 ~ 2,500
10% DoD	3,750 ~ 4,700

*Battery Power Management for Portable Devices, Yevgen Barsukov, Jirong Qian, BOOK.

- 배터리 최대 용량이 70%로 줄어드는 방전 깊이(Depth of discharge)별 충전 횟수
- 매번 배터리를 100% 사용 시 300-500번 충전 하면 배터리 용량이 70%로 줄음
- 매번 배터리를 10%만 사용 시 3,750-4,700번 충전 하면 배터리 용량이 70%로 줄음

마신러닝 학습에 필요한 전력

클라이언트 차선인식 모델 학습 시 소모 전력 측정 결과

- GPU: Nvidia A6000
- 모델 학습 시 GPU 소모 전력 평균 약 0.3kW

배터리의 수명 최적화를 위해 배터리 잔량이 높고, 충전 속도가 느린 클라이언트에게 학습 참여 우선권을 부여

충전-방전 속도에 따른 리튬 이온 배터리 수명 변화

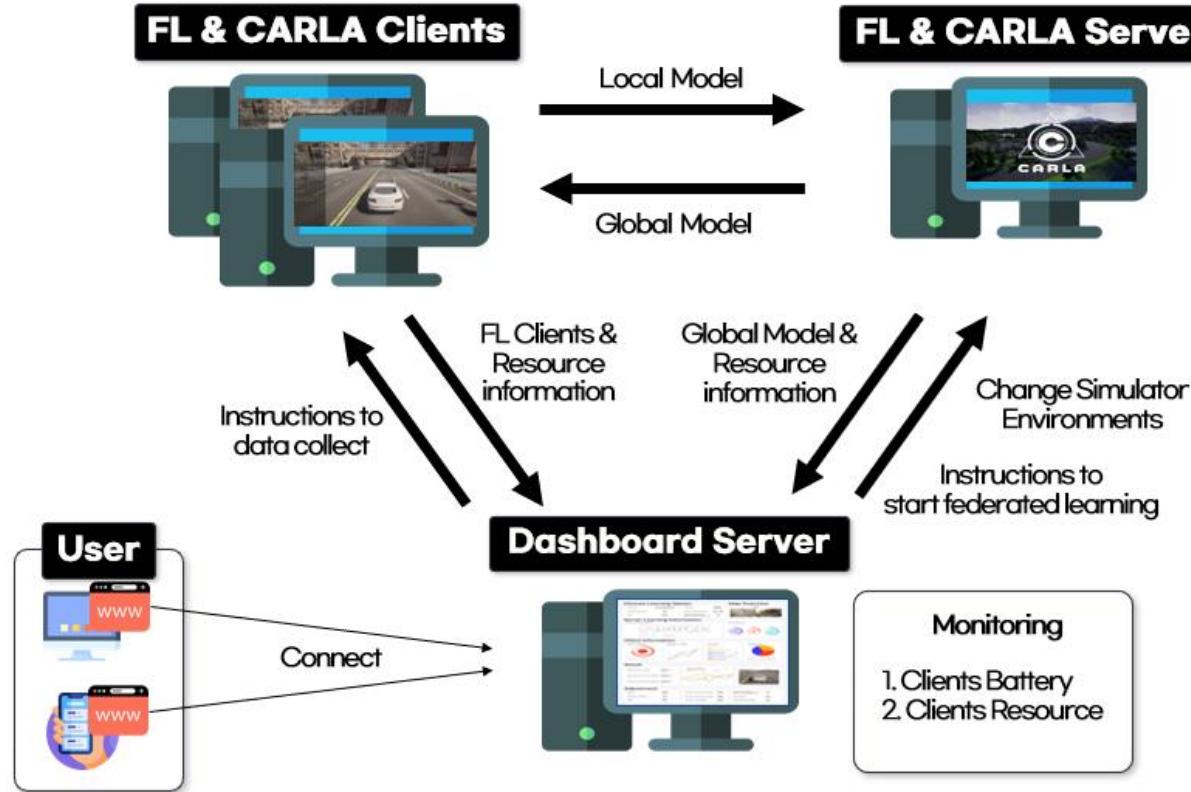
*Factors that affect cycle-life and possible degradation mechanisms of a Li-ion cell based on LiCoO₂, Samsung SDI

- C-rate(Current Rate) 의미: 배터리를 충전 또는 방전시키는 속도를 나타내는 값
- C-rate = 충전방전 전류(I_{Ch}) / 충전방전 전류(I_{Dis})
- 배터리 용량(Ah) = 배터리 용량(mAh) / 배터리 용량(mAh)
- 충전, 방전 시 C-rate가 높으면 배터리의 최대 용량이 줄어듬.

목차

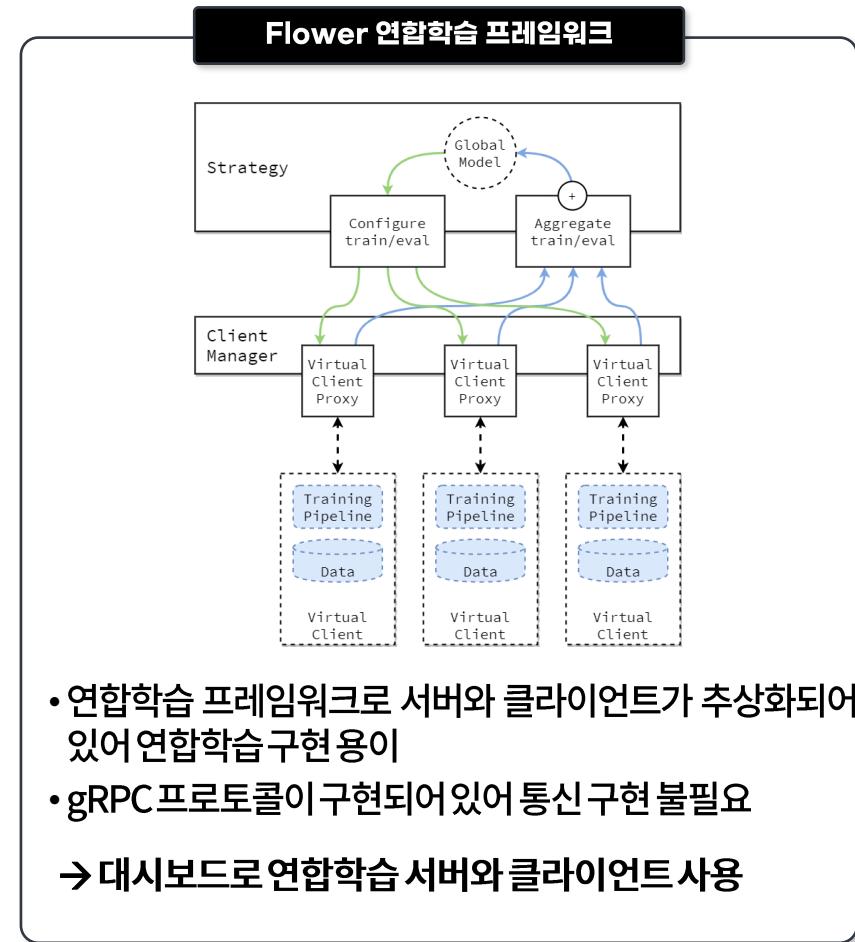
- I. 연구 배경
- II. 관련 연구
- III. 문제 정의
- IV. 제안 방법**
- V. 실험
- VI. 결론 및 개선 방향

IV. 제안 방법 - 연합학습 대시보드 개요

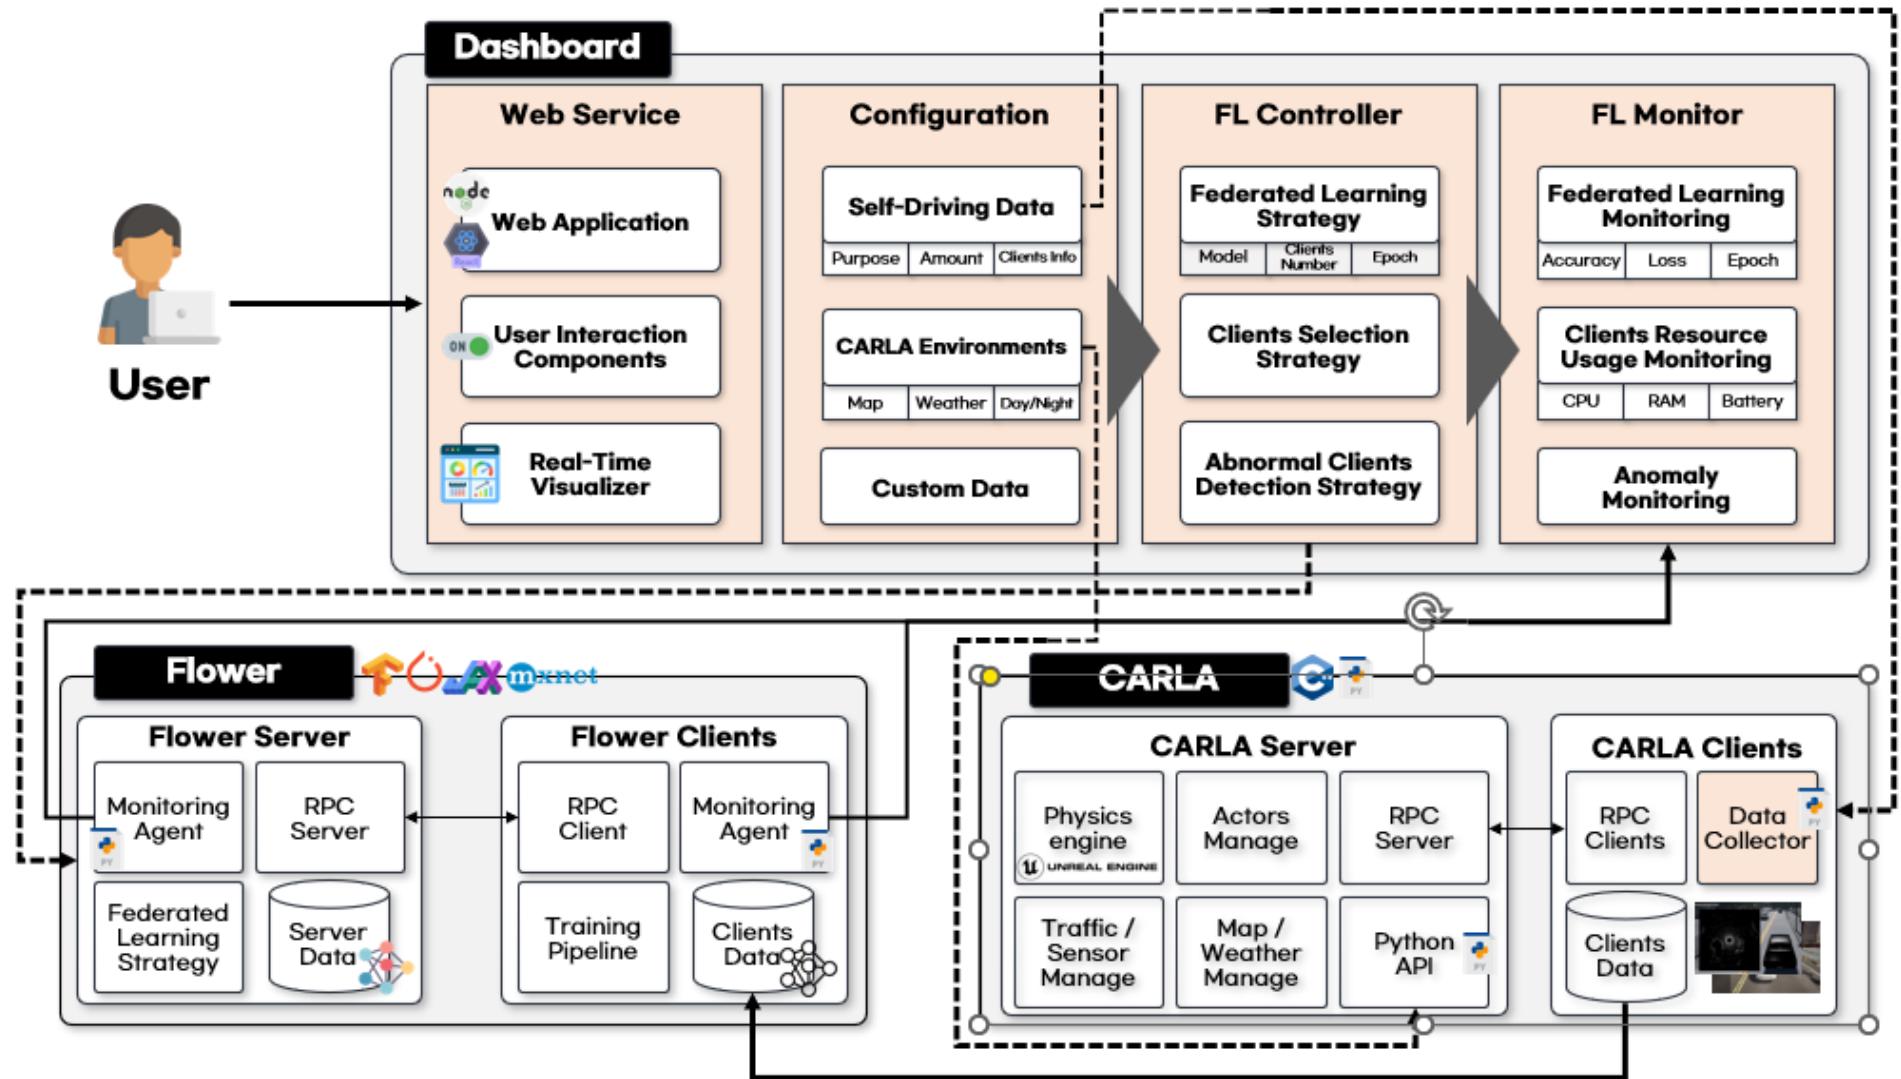


- 대시보드는 웹 기반 서비스
- 본 연구에서 제안하는 대시보드는 자율주행 시뮬레이터인 CARLA와 연합학습 프레임워크 Flower와 연동
- 데이터 수집부터 연합학습 결과 평가까지 연합학습에 필요한 모든 단계를 웹 페이지의 한 화면에서 가능

IV. 제안 방법 - CARLA, Flower



IV. 제안 방법 - 연합학습 대시보드 설계



IV. 제안 방법 - 연합학습 대시보드: 화면

- 사용자가 웹 브라우저를 통해 연합학습 대시보드에 접속한 화면

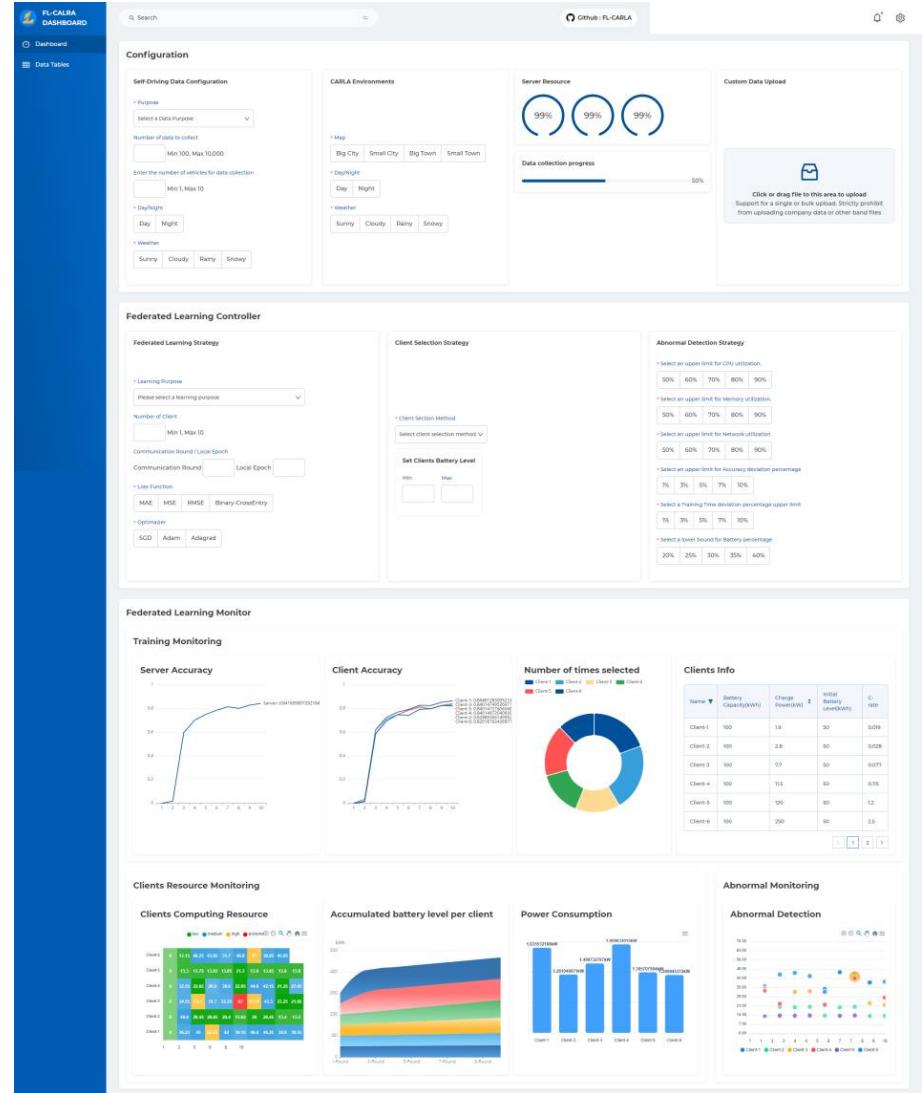
- 설계에 따라 4가지 모듈로 구성

- Configuration:** 학습에 사용할 데이터 준비

- Federated Learning Controller:** 연합학습 준비

- Federated Learning Monitor:** 연합학습 과정 모니터링

- Anomaly Monitoring:** 이상 현상 탐지



IV. 제안 방법 - 연합학습 대시보드: Configuration

The screenshot displays the 'Configuration' section of the Joint Learning Dashboard. On the left, a modal window titled 'Configuration' is open, showing the 'Self-Driving Data Configuration' settings. The configuration includes fields for 'Purpose' (dropdown menu), 'Number of data to collect' (text input: Min 100, Max 10,000), 'Enter the number of vehicles for data collection' (text input: Min 1, Max 10), 'Day/Night' (radio buttons: Day, Night), and 'Weather' (checkboxes: Sunny, Cloudy, Rainy, Snowy). To the right of the modal, the main dashboard features a 'Server Resource' section with three circular progress indicators at 99% each, labeled 'Big Town', 'Small Town', and 'Rainy'. Below this is a 'Data collection progress' bar at 50%. A 'Custom Data Upload' section contains a file icon and instructions: 'Click or drag file to this area to upload. Support for a single or bulk upload. Strictly prohibit from uploading company data or other bad files.'

1. **Self-Driving Data Configuration:** 학습 목적 선택, 수집하려는 데이터 수, 데이터 수집에 투입할 CARLA 클라이언트 수 입력
2. **CARLA Environments:** 데이터 수집 중 CARLA 환경인 Map, 낮/밤, 날씨를 변경할 수 있는 기능

IV. 제안 방법 - 연합학습 대시보드: Client Selection

The screenshot shows the 'Federated Learning Controller' interface with two main sections for 'Client Selection Strategy': 'Oort' and 'EAFL'. Each section includes a dropdown menu for 'Client Selection Method' and a configuration panel.

Oort Method Configuration:

$$Util(i) = |B_i| \underbrace{\sqrt{\frac{1}{|B_i|} \sum_{k \in B_i} Loss(k)^2}}_{Statistical utility U(i)} \times \underbrace{\left(\frac{T}{t_i}\right)^{1(T < t_i) \times \alpha}}_{Global sys utility} \quad (1)$$

Client Score(i) = Util(i)

EAFL Method Configuration:

$$reward = f \times Util(i) + (1 - f) \times power(i),$$
$$power(i) = cur_battery_level(i) - battery_used(i)$$
$$Util(i) = |B_i| \underbrace{\sqrt{\frac{1}{|B_i|} \sum_{k \in B_i} Loss(k^2)}}_{\text{Battery capacity (kWh)}} \times \left(\frac{T}{t_i}\right)^{1(T < t_i) \times \alpha}$$

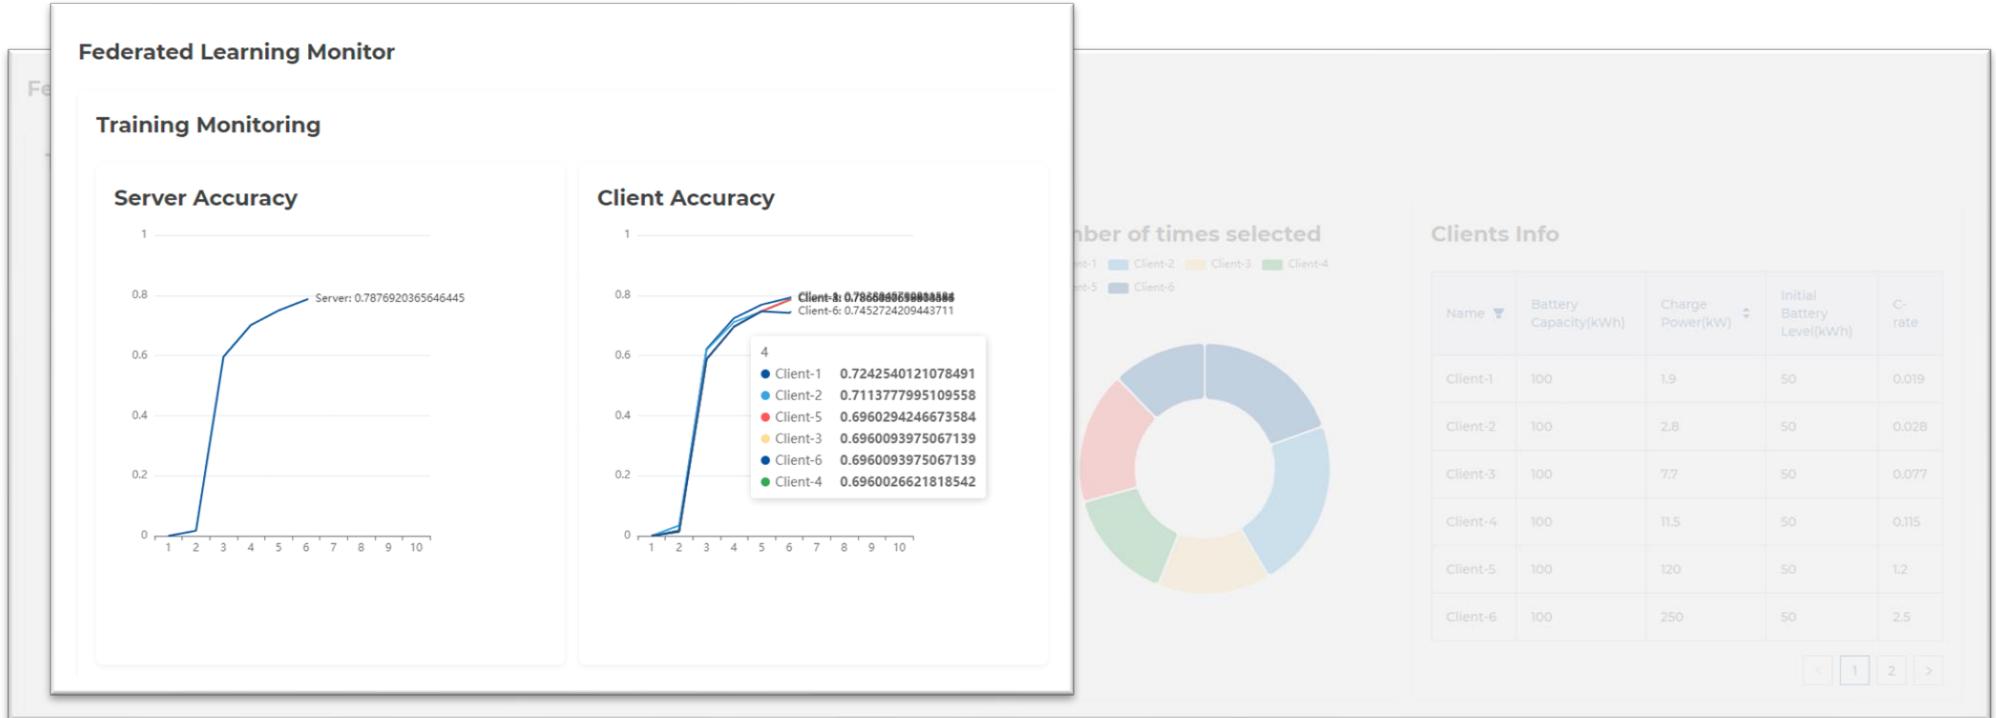
Client Score(i) = reward

f T Battery capacity(kWh)

1. **Federated Learning Strategy:** 학습 모델, 클라이언트 수, Communication Round, Local Epoch, 학습에 필요한 변수 설정
2. **Client Selection Strategy:** 클라이언트 선택 방법 선택, 각 선택 방법에 대한 내용과 필요한 변수 입력
3. **Anomaly Detection Strategy:** 대시보드가 모니터링하는 변수들의 이상치에 대한 기준 설정

IV. 제안 방법 - 연합학습 대시보드: Accuracy

연합학습 대시보드 화면 – Federated Learning Monitor 모듈: 연합학습 과정 모니터링

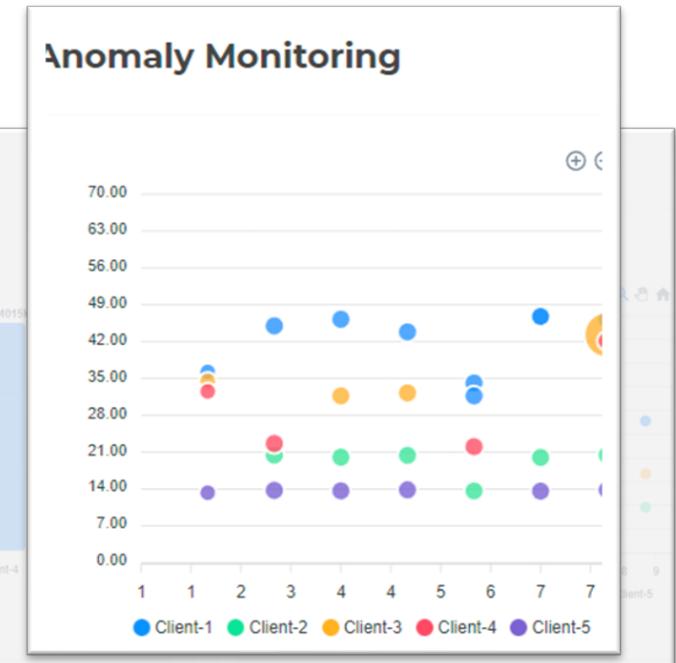
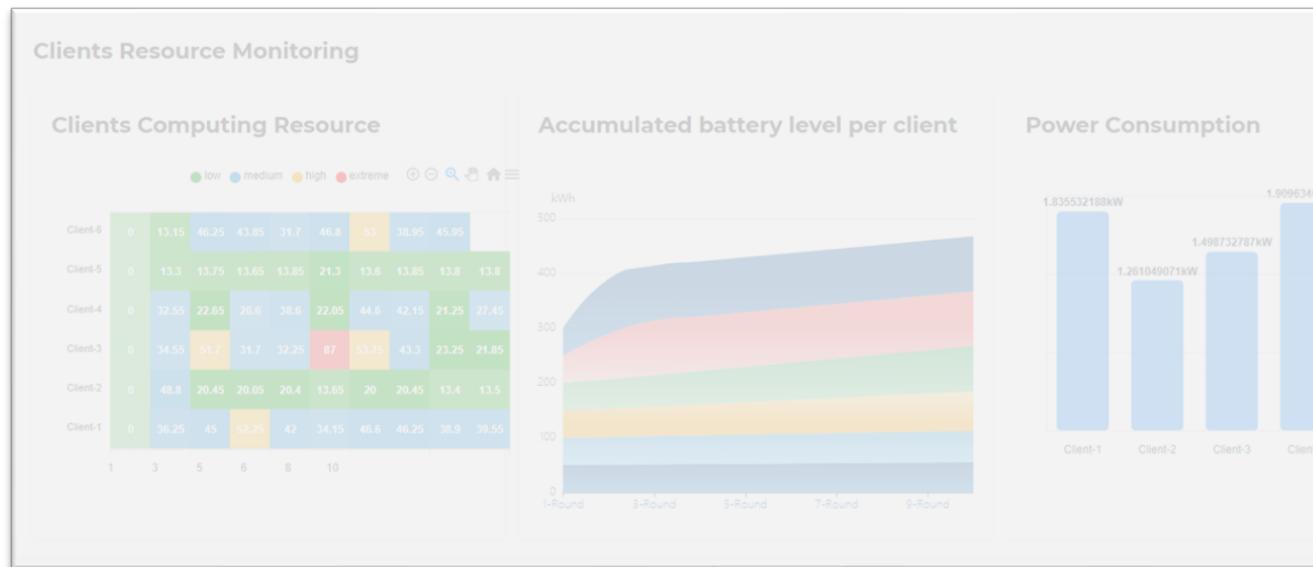


1. Training Monitoring

1. Server Accuracy, Clients Accuracy: 연합학습의 서버, 클라이언트의 정확도 확인
2. Number of times selected: 클라이언트 선택 방법에 의해 학습에 참여한 클라이언트 별 수 확인
3. Clients Info: 클라이언트의 식별자 및 배터리에 관한 정보 확인

IV. 제안 방법 - 연합학습 대시보드: Abnormal Detection

연합학습 대시보드 화면 – Federated Learning Monitor 모듈: 연합학습 과정 모니터링



2. Clients Resource Monitoring

1. Clients Computing Resource: 클라이언트들의 자원 사용률을 Heatmap 차트로 확인
2. Accumulated battery level per client: 클라이언트들의 배터리 잔량(kWh)를 확인
3. Power Consumption: 클라이언트들의 전력 소모량을 확인

3. Anomaly Monitoring: 이상 징후 탐지

IV. 제안 방법 - 배터리 수명 최적화를 위한 클라이언트 선택 방법

클라이언트별로 Reward를 계산하여, 다음 라운드 학습에 참여할 클라이언트를 Reward순서로 선택
사용자는 데이터 분포와 배터리 상태 두 가지의 정량화된 $f(0 \leq f \leq 1)$ 로 가중치를 결정

$$Reward = f \times Util(i) + (1 - f) \times Battery_Score(i)$$

$$Util(i) = |B_i| \sqrt{\frac{1}{|B_i|} \sum_{k \in B_i}^b Loss(k)^2} \times \left(\frac{T}{t_i}\right)^{1(T < t_i) \times \alpha}$$

*Oort: Efficient Federated Learning via Guided Participant Selection. OSDI'21

- 클라이언트가 보유한 데이터가 글로벌 모델에 얼마나 기여할 수 있는지 정량화

$$\begin{array}{ccc} |B_i| & \sqrt{\frac{1}{|B_i|} \sum_{k \in B_i}^b Loss(k)^2} & \left(\frac{T}{t_i}\right)^{1(T < t_i) \times \alpha} \\ \text{데이터크기} & \text{모델Loss} & \text{Time Ratio} \end{array}$$

$$Battery_Score(i) = \omega \times battery_level_i + (1 - \omega) \times \left(\frac{C_rate_i}{\max_{j \in Clients} (C_rate_j)} \right)^{-1}$$

- 클라이언트의 배터리 잔량과 C-rate를 모두 고려
- 배터리 잔량이 높을수록, C-rate가 낮을수록 고점부여
- 사용자는 $\omega (0 \leq \omega \leq 1)$ 값을 설정하여 두 변수에 가중치 결정
- 자율주행차가 충전 중일 경우에만 학습에 참여하므로 배터리 잔량이 낮고 C-rate가 높은 상태라면 배터리 수명에 좋지 않기에 낮은 점수 부여

$$C\text{-rate} = \frac{\text{충전방전 전류(A)}}{\text{배터리용량(Ah)}} = \frac{\text{충전방전 전력(W)}}{\text{배터리용량(Wh)}}$$

C-rate(Current Rate): 배터리를 충전 또는 방전시키는 속도를 나타내는 값

목차

- I. 연구 배경
- II. 관련 연구
- III. 문제 정의
- IV. 제안 방법
- V. 실험
- VI. 결론 및 개선 방향

V. 실험 - 목표

클라이언트로부터 발생하는 데이터 분석과 처리

자율주행 연합학습에서 클라이언트의 배터리 수명과 학습 성능 간 트레이드 오프 관계

연합학습 대시보드 사례 분석

- 목표: 이상 클라이언트 탐지
- 방법: 대시보드의 Anomaly Detection 도구 활용



배터리 수명 최적화 클라이언트 선택 방법 실험

- 목표: 제안 방법으로 선택된 클라이언트들의 낮은 C-rate 값과 모델의 성능 저하 최소화
- 방법: 다른 클라이언트 선택 방법들과 비교 실험

Study	T	α	f	ω
제안 방법	500	1	0.2	0.2
EAFL[6]	500	1	0.2	-
Oort[7]	500	1	-	-
Random	-	-	-	-

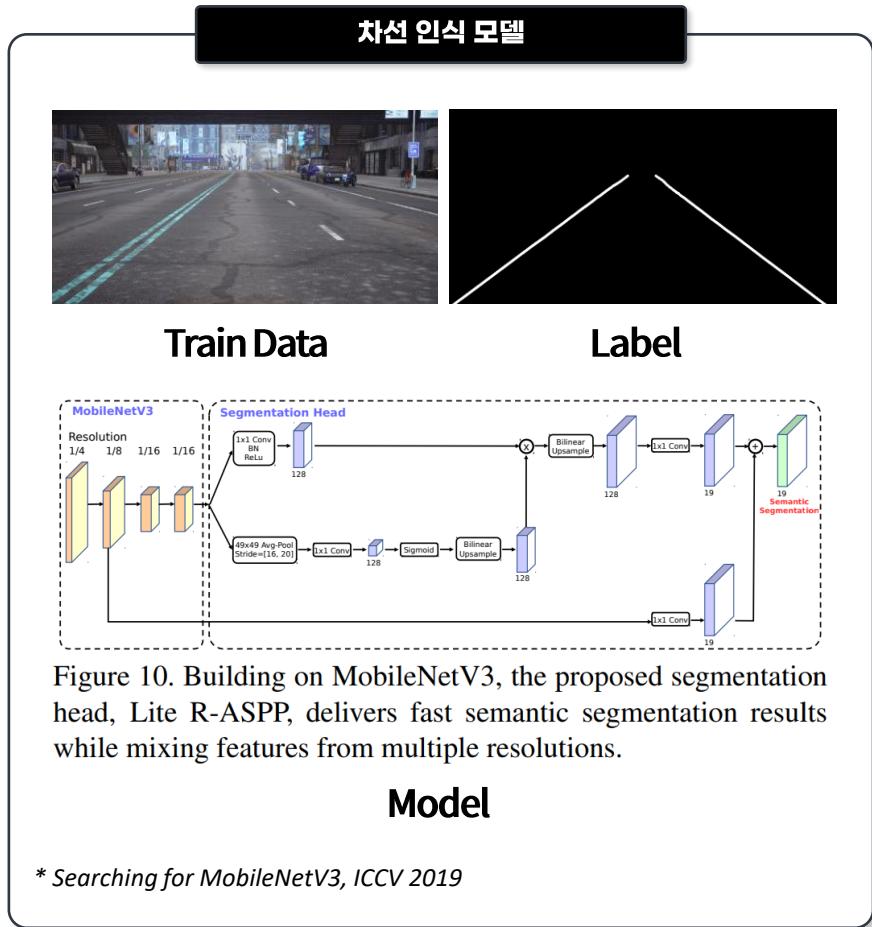
T: 클라이언트 학습 시간 기대치(초)

α : 클라이언트 학습 시간이 T를 초과하였을 시 패널티 계수

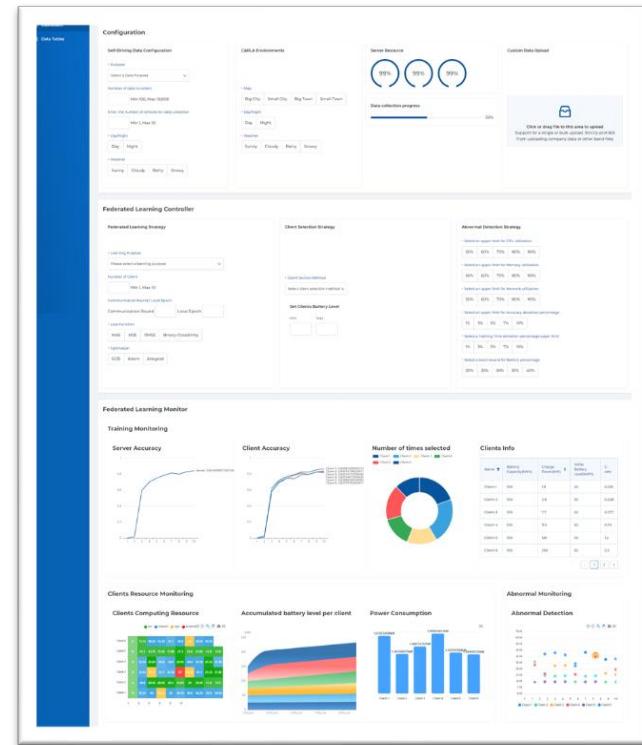
f: Util(i)와 BatteryScore(i) 가중치 계수

ω : 배터리 잔량 비율과 충전 속도와의 가중치 계수

V. 실험 - 연합학습 대시보드 이상 클라이언트 탐지 실험: 개요

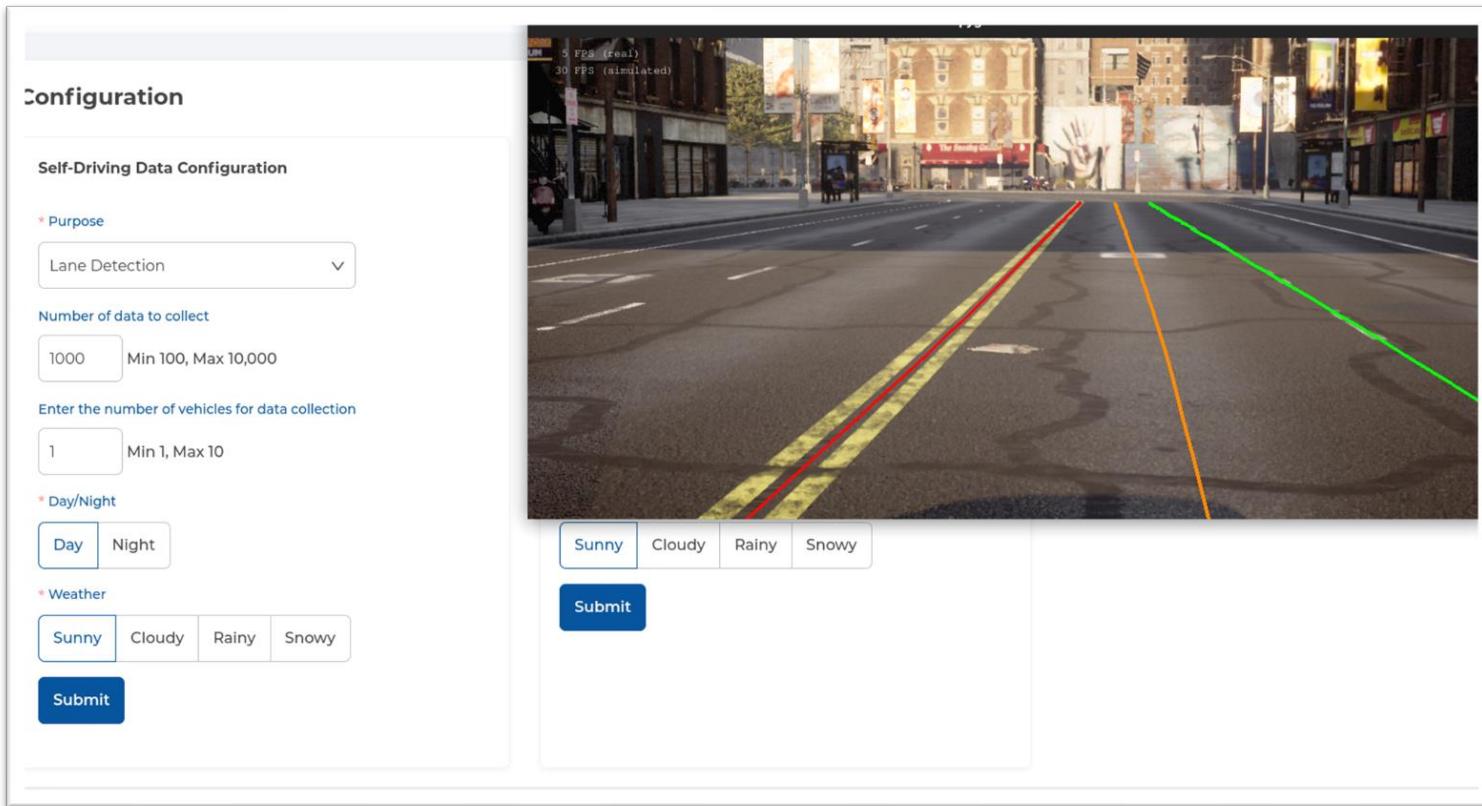


차선 인식 모델을 연합학습 대시보드를 통해 학습



V. 실험 - 연합학습 대시보드 이상 클라이언트 탐지 실험: 데이터 수집

차선 인식 모델을 학습하기 위한 데이터 준비 단계 - Configuration



1. 학습 목적, 수집할 데이터 개수, 수집에 사용할 클라이언트 수와 초기 CARLA 환경을 설정 후 'Submit' 버튼 클릭
2. CARLA 클라이언트가 Spawn하며 학습에 사용할 이미지와 Label을 수집

V. 실험 - 연합학습 대시보드 이상 클라이언트 탐지 실험: 연합학습 준비

차선 인식 모델을 학습하기 위한 데이터 준비 단계 - Configuration

The screenshot shows a configuration interface for Federated Learning. It is divided into three main sections: Federated Learning Strategy, Client Selection Strategy, and Abnormal Detection Strategy.

- Federated Learning Strategy:**
 - * Learning Purpose: Lane Detection
 - Number of Client: 6 (Min 1, Max 10)
 - Communication Round / Local Epoch: Communication Round 10, Local Epoch 3
 - * Loss Function: MAE (selected)
 - * Optimizer: SCD (selected)
- Client Selection Strategy:**
 - * Client Selection Method: Random
 - Random Method Configuration: Random selection method requires no additional settings
 - Set Clients Battery Level: Min 50, Max 100
- Abnormal Detection Strategy:**
 - * Select an upper limit for CPU utilization: 50% (selected)
 - * Select an upper limit for Memory utilization: 50% (selected)
 - * Select an upper limit for Network utilization: 50% (selected)
 - * Select an upper limit for Accuracy deviation percentage: 1% (selected)
 - * Select a Training Time deviation percentage upper limit: 1% (selected)
 - * Select a lower bound for Battery percentage: 20% (selected)

- 데이터준비가완료된후, Federated Learning Controller를 통해연합학습을 시작
- Federated Learning Starategy에서학습에필요한매개변수를설정
- 클라이언트선택방법은랜덤방식을사용하고,클라이언트의배터리잔량(kWh)을할당할범위를입력
- 학습시이상클라이언트를판단할기준을최하옵션을설정한다.

V. 실험 - 연합학습 대시보드 이상 클라이언트 탐지 실험: 연합학습 수행

차선 인식 모델 학습 설정 – Federated Learning Controller

The screenshot shows the 'Federated Learning Controller' interface with the following configuration:

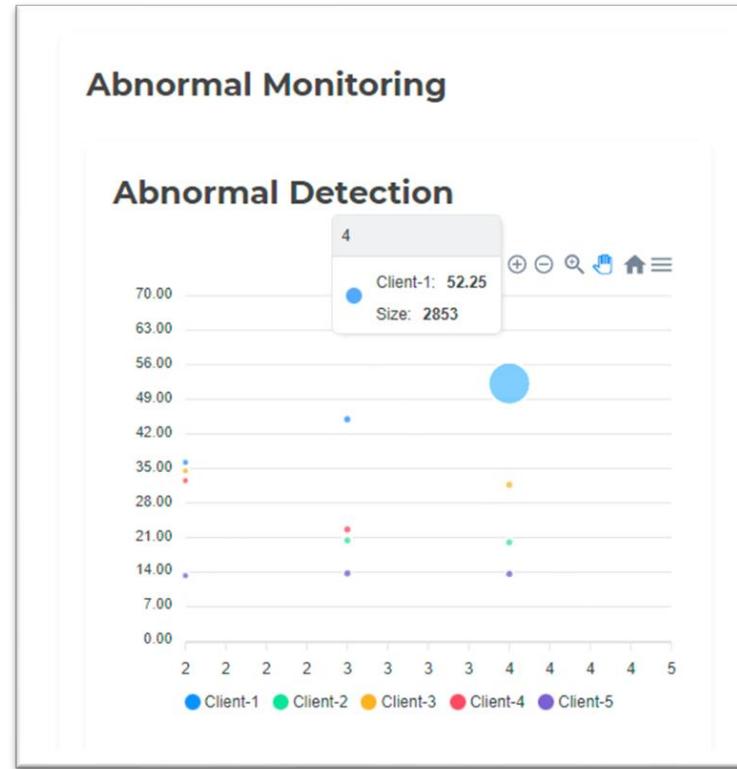
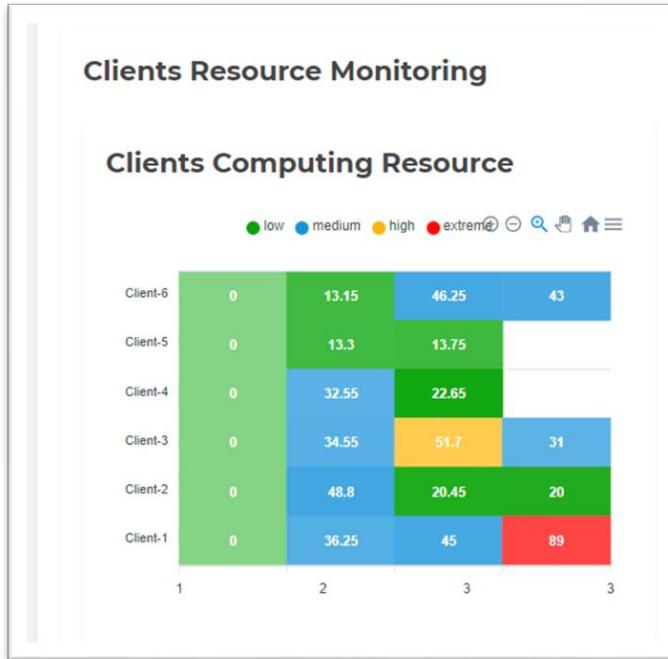
- Federated Learning Strategy**:
 - * Learning Purpose: Lane Detection
 - Number of Client: 6 (Min 1, Max 10)
 - Communication Round / Local Epoch:
 - Communication Round: 10
 - Local Epoch: 3
 - * Loss Function: MAE (selected)
 - * Optimizer: SGD (selected)
- Client Terminal**:

```
(base) tj@carla:~$ ps -alh | grep fL_
0 1000 2539276 2539274 20 0 4416800 194372 fute
0 1000 2539409 1559 20 0 44338164 6401388 fu
0 1000 2539410 1559 20 0 39256824 6395064 fu
0 1000 2539411 1559 20 0 38399300 6423936 fu
0 1000 2539412 1559 20 0 38550736 6413856 fu
0 1000 2539413 1559 20 0 40380920 6402288 fu
0 1000 2539414 1559 20 0 25360680 5337900 fu
0 1000 2540641 2537026 20 0 10340 648 pipe_r
(base) tj@carla:~$
```
- Data View**: A table showing training progress for 7 clients (rows 1-7).

	A	B	C	D	E	F	G	H	I	J	char
1	learning_step	id	method	server_round	selected	accuracy	loss	train_time	battery_level		
2	0 training	1.9kW	random	1	1	0	0	0	0		50
3	1 training	2.8kW	random	1	1	0	0	0	0		50
4	2 training	7.7kW	random	1	1	0	0	0	0		50
5	3 training	11.5kW	random	1	1	0	0	0	0		50
6	4 training	120.0kW	random	1	1	0	0	0	0		50
7											

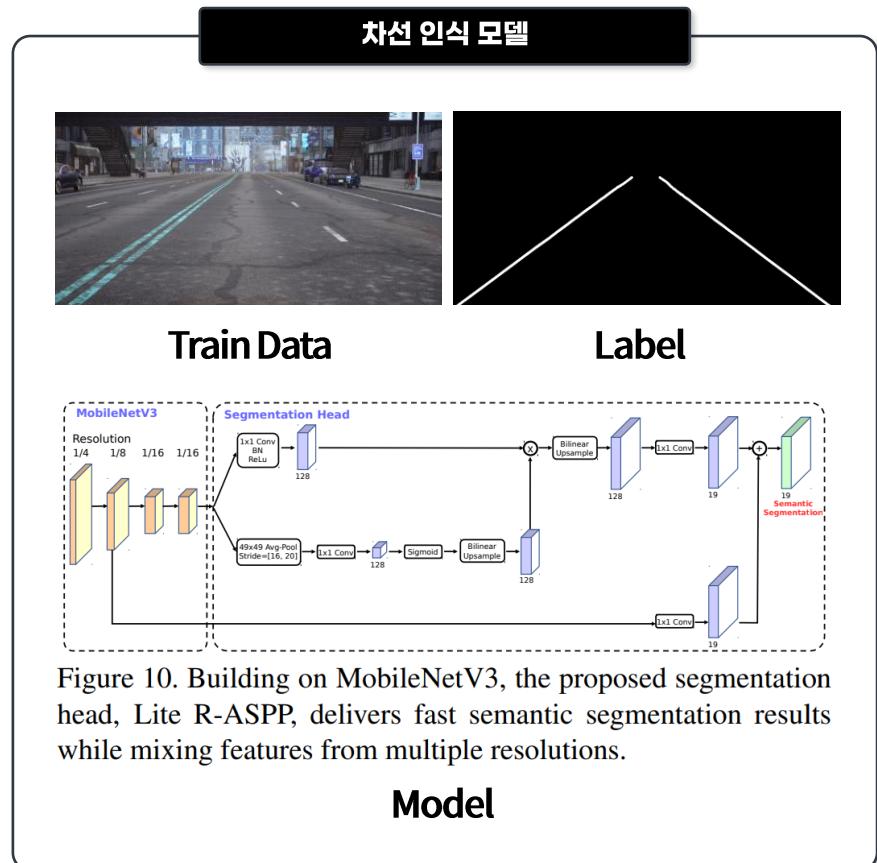
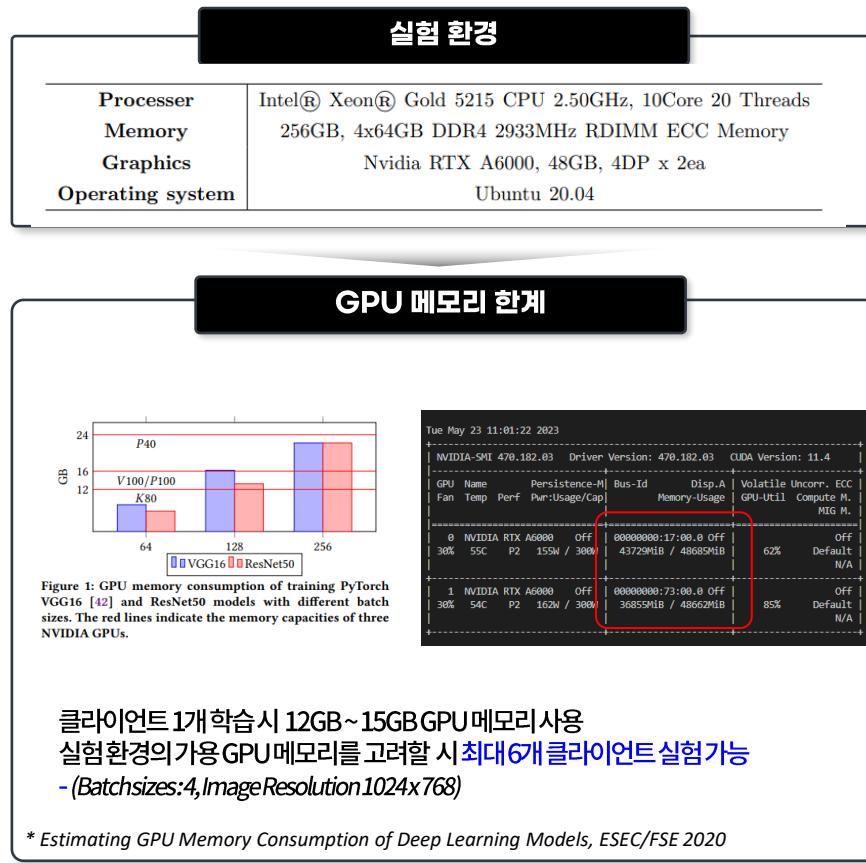
1. 학습 시작에 필요한 변수를 설정 후, Flower 서버, 클라이언트 학습 시작
2. 정보를 csv, json 파일로 생성.

V. 실험 - 연합학습 대시보드 이상 클라이언트 탐지 실험: 이상 클라이언트 식별



1. 학습 도중 사용자가 설정한 이상치 기준을 넘는 클라이언트가 발생할 시 시각화 도구로 확인 가능 → 사용자가 상황에 맞게 대처
2. (화면) 클라이언트 1번이 4번째 라운드에 어떠한 이유로 자원 사용량이 급격히 상승했으며, 학습 시간도 타 클라이언트 대비 증가

V. 실험 - 배터리 수명 최적화를 위한 클라이언트 선택 방법: 실험 환경



V. 실험 - 배터리 수명 최적화를 위한 클라이언트 선택 방법: 실험 데이터

데이터 수집 환경: 날씨(맑음, 호우, 안개), 시간대(낮/밤)



환경	Training	Evaluation
낮, 맑음	920	83
낮, 호우	917	86
낮, 안개	935	68
밤, 맑음	935	68
밤, 호우	929	74
밤, 안개	922	81

V. 실험 - 배터리 수명 최적화를 위한 클라이언트 선택 방법: 비교 대상

Study	T	α	f	ω
제안 방법	500	1	0.2	0.2
EAFL[6]	500	1	0.2	-
Oort[7]	500	1	-	-
Random	-	-	-	-

1. T: 클라이언트 학습 시간 기대치(초)
2. α : 클라이언트 학습 시간이 T를 초과하였을 시 패널티 계수
3. f: Util(i)와 Battery Score(i) 가중치 계수
4. ω : 배터리 잔량 비율과 충전 속도의 가중치 계수

$$Reward = f \times Util(i) + (1 - f) \times Battery_Score(i)$$

$$Util(i) = |B_i| \sqrt{\frac{1}{|B_i|} \sum_{k \in B_i}^b Loss(k)^2} \times \left(\frac{T}{t_i}\right)^{1(T < t_i) \times \alpha}$$

$$Battery_Score(i) = \omega \times battery_level_i + (1 - \omega) \times \left(\frac{C_rate_i}{\max_{j \in Clients}(C_rate_j)} \right)^{-1}$$

1. Oort: 클라이언트의 데이터가 글로벌 모델에 얼만큼 기여할 수 있는지 고려, Loss가 클수록 유리 $\rightarrow Util$
2. EAFL: 클라이언트의 글로벌 모델 기여도와 배터리 잔량을 고려, 배터리 잔량이 높고 Util 값이 높으면 유리
3. 제안 방법: Util 값, 배터리 잔량과 C-rate 고려

V. 실험 - 배터리 수명 최적화를 위한 클라이언트 선택 방법: 클라이언트 설정

전기차 충전기 정보

	AC LEVEL 1	AC LEVEL 2	MODES 1	MODES 2-3	GB/T	MOBILE CONNECTION	WALL CONNECTION
Maximum power	1.9 kW	19.2 kW	4 kW (13.3 kW)	8 kW (22 kW)	7 kW (12.8 kW)	1.9 kW (7.7 kW)	2.8 kW (11.5 kW)
Input voltage	120 V, single phase	240 V, split phase	250 V, single phase (480 V, three phase)	250 V, single phase (480 V, three phase)	250 V, single phase (400 V, three phase)	120 V, single phase (240 V, single phase)	208 V, single phase (250 V, single phase)
Maximum current	16 A	80 A	16 A	32 A	32 A	16/32 A	48 A
Communication	PLC	PLC	None	PLC	CAN	CAN	CAN
Region	United States, Japan, South Korea	Europe, Australia	China, India	Global	Global	Global	Global
Related standards	• IEC 61851-22/23 • IEC 62196-2 • SAE J1772-2017	• IEC 61851-22/23 • IEC 62196-2	• GB/T 20234-2 • IEC 62196-2	• IEC 62196-2	• IEC 62196-2	• IEC 62196-2	• IEC 62196-3
Vehicle to device	Under development	Under development	Under development	No	No	No	No
Plug type							
Example							
Time/100 km ⁱ	13.73 min	4.4 min	1.96 min	11.44 min	2.74 min	18.95 km	
Range/5 min ⁱ	36.4 km	113.54 km	254.73 km	43.67 km			
Examples							

* Electric Vehicle Charging Infrastructure, IEEE Industrial Electronics Magazine

클라이언트 학습 환경 설정

배터리 용량 (kWh)	충전기	충전 전력(kW)	C-rate	데이터 환경	데이터 수
100	Mobile Connection	1.9	0.019	낮, 맑음	1,003
	Wall Connection	2.8	0.028	낮, 호우	1,003
	Mobile Connection	7.7	0.077	낮, 안개	1,003
	Wall Connection	11.5	0.115	밤, 맑음	1,003
	Super Charger V2	120	1.2	밤, 호우	1,003
	Super Charger V3	250	2.5	밤, 안개	1,003

클라이언트 6개의 배터리 용량을 100kWh(테슬라 모델 S)
6가지 충전기를 사용할 시 충전 전력과 C-rate 계산

클라이언트 학습 소모 전력 설정

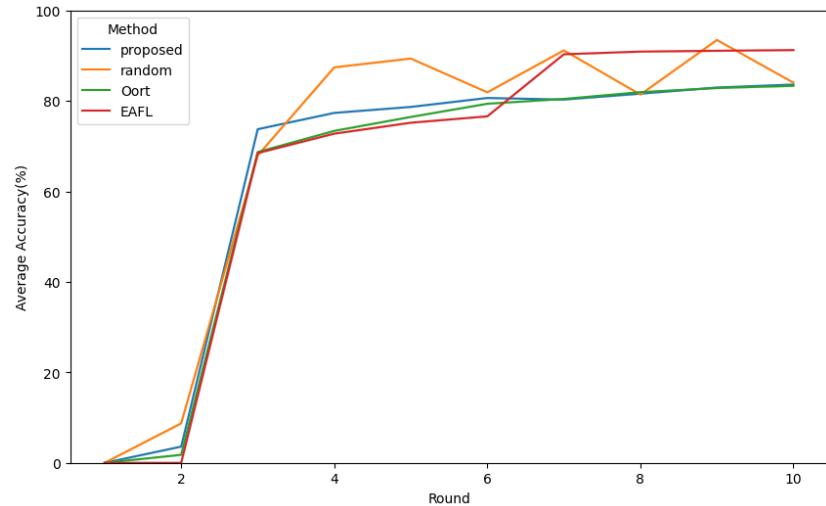
NVIDIA GPU Power Consumption

Power Usage (W) vs Time (min)

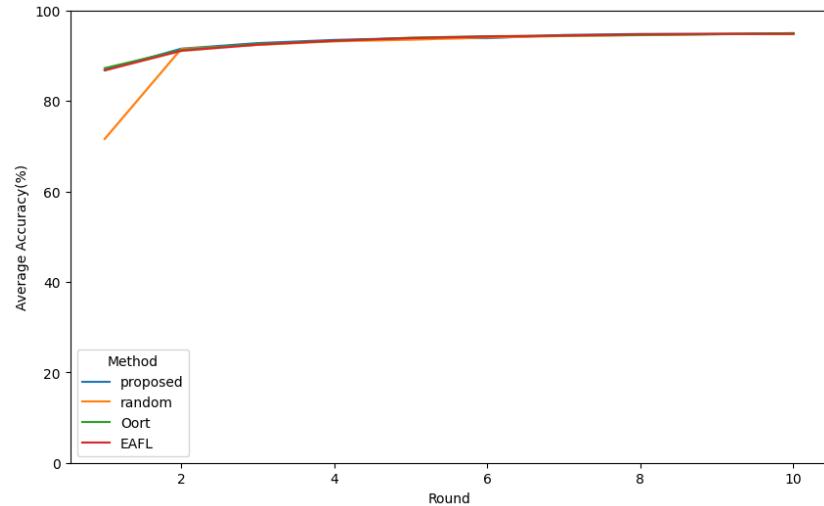
학습 시 소요되는 GPU 전력 측정 결과인 200W~300W 부여

V. 실험 - 배터리 수명 최적화를 위한 클라이언트 선택 방법 : 정확도 비교

로컬 모델들의 평균 정확도



글로벌 모델의 정확도



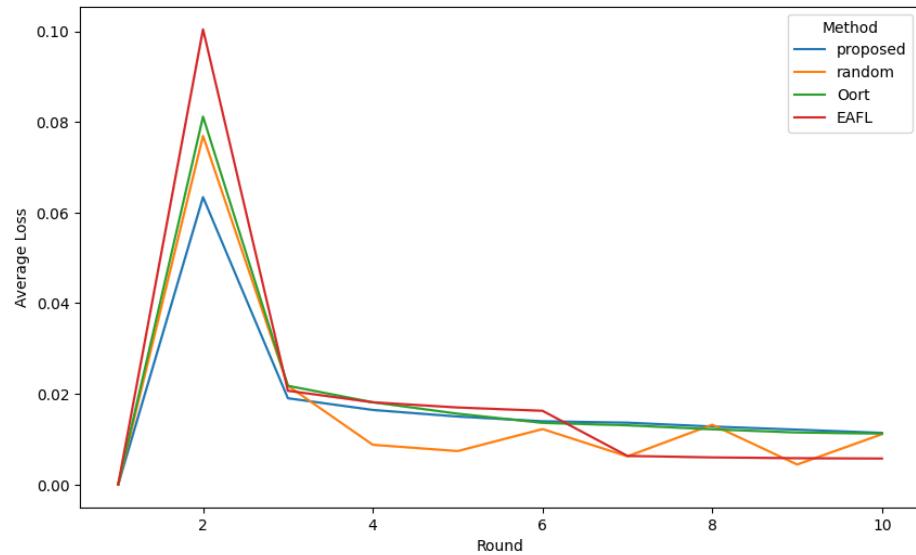
학습 종료 후 정확도 비교

	로컬 모델들의 평균 정확도(%)	글로벌 모델 정확도(%)
제안방법	0.8362	0.9494
EAFL	0.9124	0.9480
Oort	0.8333	0.9500
Random	0.8403	0.9476

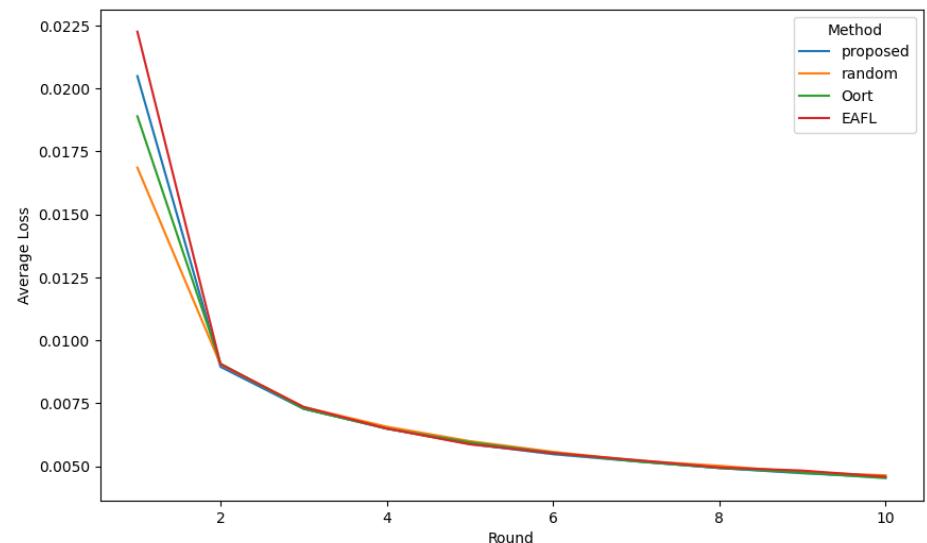
제안 방법으로 학습한 글로벌 모델의 정확도가 Oort 방식과 약 0.0006%의 차이

V. 실험 - 배터리 수명 최적화를 위한 클라이언트 선택 방법: 손실 비교

로컬 모델들의 평균 손실



글로벌 모델의 손실



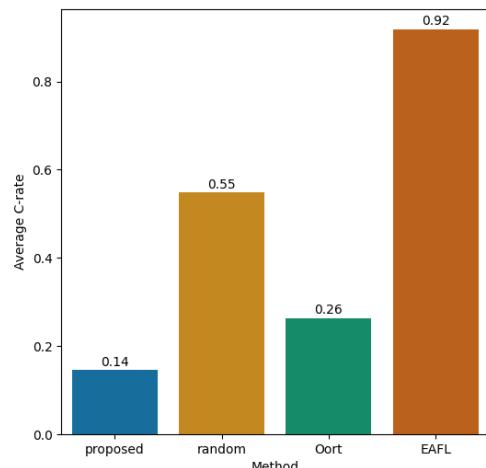
학습 종료 후 손실 비교

	로컬 모델들의 평균 손실	글로벌 모델 손실
제안방법	0.01140	0.00456
EAFL	0.00574	0.00459
Oort	0.01124	0.00453
random	0.01111	0.00464

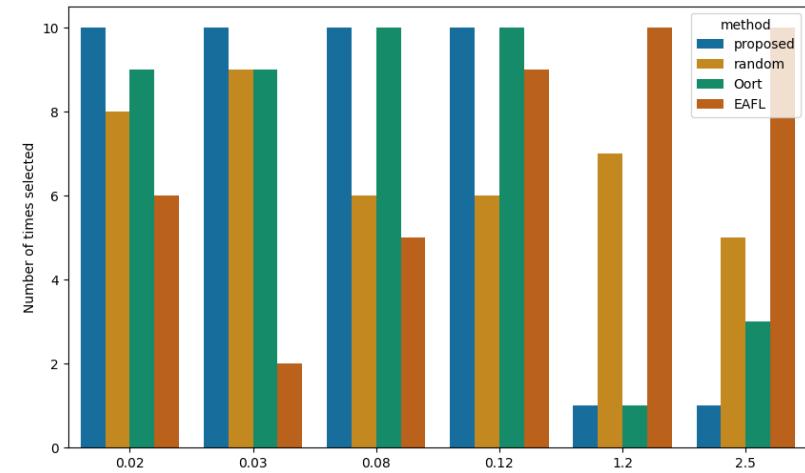
제안 방법으로 학습한 글로벌 모델의 손실이 Oort 방식과 약 0.00003 차이

V. 실험 - 배터리 수명 최적화를 위한 클라이언트 선택 방법: C-rate 비교

선택된 클라이언트의 평균 C-rate 비교



C-rate별 선택된 횟수 비교



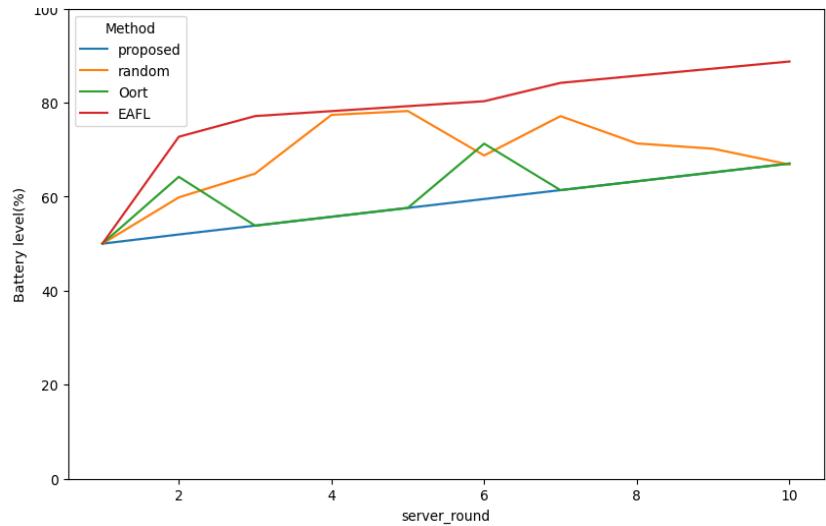
C-rate 비교

	평균 C-rate	C-rate별 선택된 횟수					
		0.02	0.03	0.08	0.12	1.2	2.5
제안방법	0.14	10	10	10	10	1	1
EAFL	0.92	6	2	5	9	10	10
Oort	0.26	9	9	10	10	1	3
random	0.55	6	2	5	9	10	10

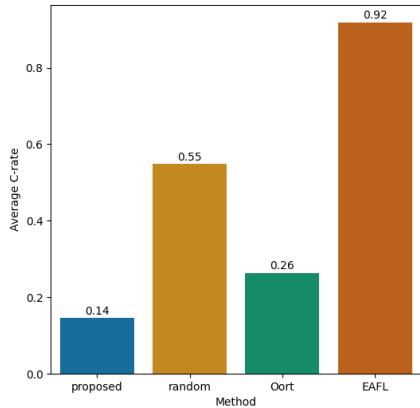
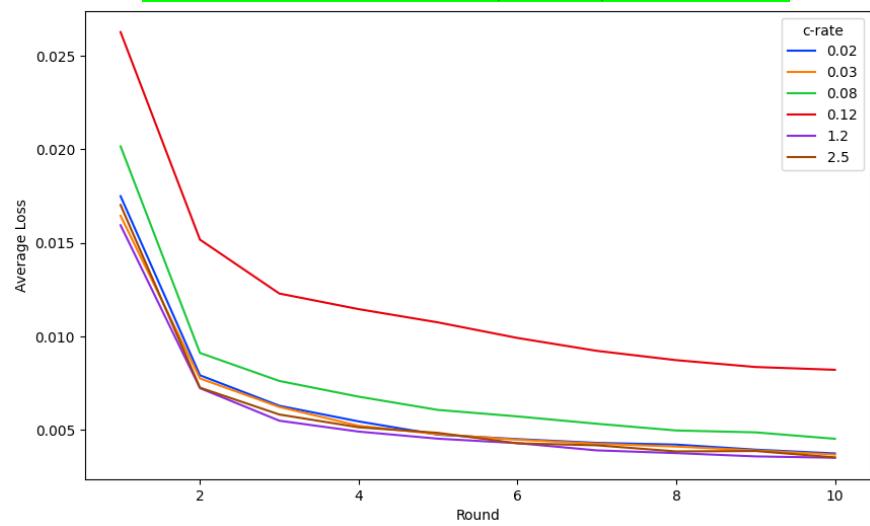
제안 방법의 선택된 클라이언트의 평균 C-rate가 0.14로 가장 낮음, EAFL C-rate의 약 15% 수준

V. 실험 - 배터리 수명 최적화를 위한 클라이언트 선택 방법: 결과 분석

선택된 클라이언트의 평균 배터리 잔량 비교



Oort방법의 클라이언트(C-rate)별 손실 비교



- EAFL 방법으로 선택된 클라이언트의 평균 C-rate가 높음
- 이유: 충전 전력이 높을수록 배터리 충전도 빠름
- Oort 방법으로 선택된 클라이언트의 평균 C-rate가 랜덤 및 EAFL 보다 낮음
- 이유: C-rate가 0.08, 0.12인 클라이언트가 Loss가 높아 선택됨.

목차

- I. 연구 배경
- II. 관련 연구
- III. 문제 정의
- IV. 제안 방법
- V. 실험
- VI. 결론 및 개선 방향

VI. 결론 및 개선 방향

1. 연합학습 대시보드

- 기존 CLI 환경에서 제한되는 분석 작업을 시각화 도구로 개선
- 연합학습의 데이터 수집부터 결과 분석 까지 모든 과정을 수행할 수 있게 함
- 개선 방향
 - ① 시각화 도구 동작 구현: 현재는 70% 구현(미구현: 데이터 수집 현황, 커스텀 데이터 업로드, 학습 모델 설정 기능)
 - ② 클라우드 서비스 연동: GPU Memory의 한계로 클라이언트 수 확장 불가하여 가상화 및 클라우드 서비스 연동 필요
 - ③ 시각화 도구 개선 및 추가

2. 배터리 수명 최적화를 위한 클라이언트 선택 방법

- 연합학습에 참여하는 클라이언트의 C-rate를 고려하여 배터리 수명을 최적화 할 수 있도록 함(EAFL 방법의 15%로 줄임)
- 개선 방향: 리튬 이온 배터리 수명에 영향을 주는 온도와 같은 다른 변수들의 영향도 고려한 클라이언트 선택 방법 필요

End